

Детекција и класификација на бенигни и малигни кожни заболувања базирано на алгоритми и модели од машинско учење

Сретен Главинчески

Февруари 2025

Апстракт

Целта на овој проект пред се е да обезбеди систем за детекција, а понатаму за класификација на кожни заболувања, со посебен фокус на разликување/идентификација помеѓу бенигни и малигни форми на рак, базирано на модели од вештачка интелигенција и машинско учење. Меѓутоа, точното идентификување дали кожното заболување е бенигно или малигно, претставува предизвик, токму поради суптилните разлики помеѓу различните типови на кожни болести. Овој проект не претставува само автоматизација на процесот на детекција, туку и обезбедува поточно и сигурно класифицирање преку интеграција на повеќе модели од вештачка интелигенција.

1. Вовед

Се поголемата зачестеност на ваков тип на заболувања поттикнува поголем број истражувачи да работат на тематиката, односно изработка на алгоритми базирани на машинско учење за поточна детекција и идентификација на истите, бидејќи е важно е за рано откривање на овие животозагрозувачки видови на кожни болести, односно бенигни заболувања.

Во трудот со наслов "*A Dermoscopic Skin Lesion Classification Technique Using YOLO-CNN and Traditional Feature Model*" [1] се истражува метод за класификација на бенигни и малигни кожни заболувања користејќи *YOLO* архитектура, комбинирана со поедноставни техники за извлекување на карактеристики, како текстура и боја. Конкретно, *YOLO* моделот се користи за идентификација на објектите од интерес, по што карактеристиките на текстурата се извлекуваат со помош на *Gray-Level Co-occurrence Matrix (GLCM)* алгоритмот, а карактеристиките на бојата со *Color Level Co-occurrence Matrix (CLCM)*. Овие обележја се спојуваат со карактеристиките генерирани од *YOLO* и се внесуваат во *Fully Connected Network (FCN)* за класификација, што резултира со подобрена точност во споредба со самостојните *YOLO* модели.

Дел од архитектурите еволуираат и со тоа се подобруваат во нивните прецизности и предвидувања, па таков е примерот во трудот "*Skin Cancer Recognition Using Unified Deep Convolutional Neural Networks*" [2] каде се прави споредба на различни верзии на *YOLO* архитектурата, имено *YOLOv3*, *YOLOv4*, *YOLOv5* и *YOLOv7* за класификација на кожни заболувања. Моделите се тестираат на датасет од 2750 слики, и притоа за валидација на

точноста на моделот се користат метрики како: *Intersection over Union (IoU)*, *Mean Average Precision (mAP)*, и *F1-measure*. Значајно е да се напомене и тоа што во оваа студија се користат методи за балансирање на бројната застапеност на секоја од класите, со цел справување со класна небалансираност.

Користење класификатори после извлекување карактеристики од слика претставува честа практика во машинска визија, па така во “*Skin Disease Detection And Classification*” [3] може да согледаме како после алгоритмите за претпроцесирање, сегментација на слика, и извлекување на обележја, се користи *Decision Tree* класификатор, трениран токму на извлечените обележја од *GLCM (Grey Level Co-occurrence Matrix)*.

2. Преглед на архитектура

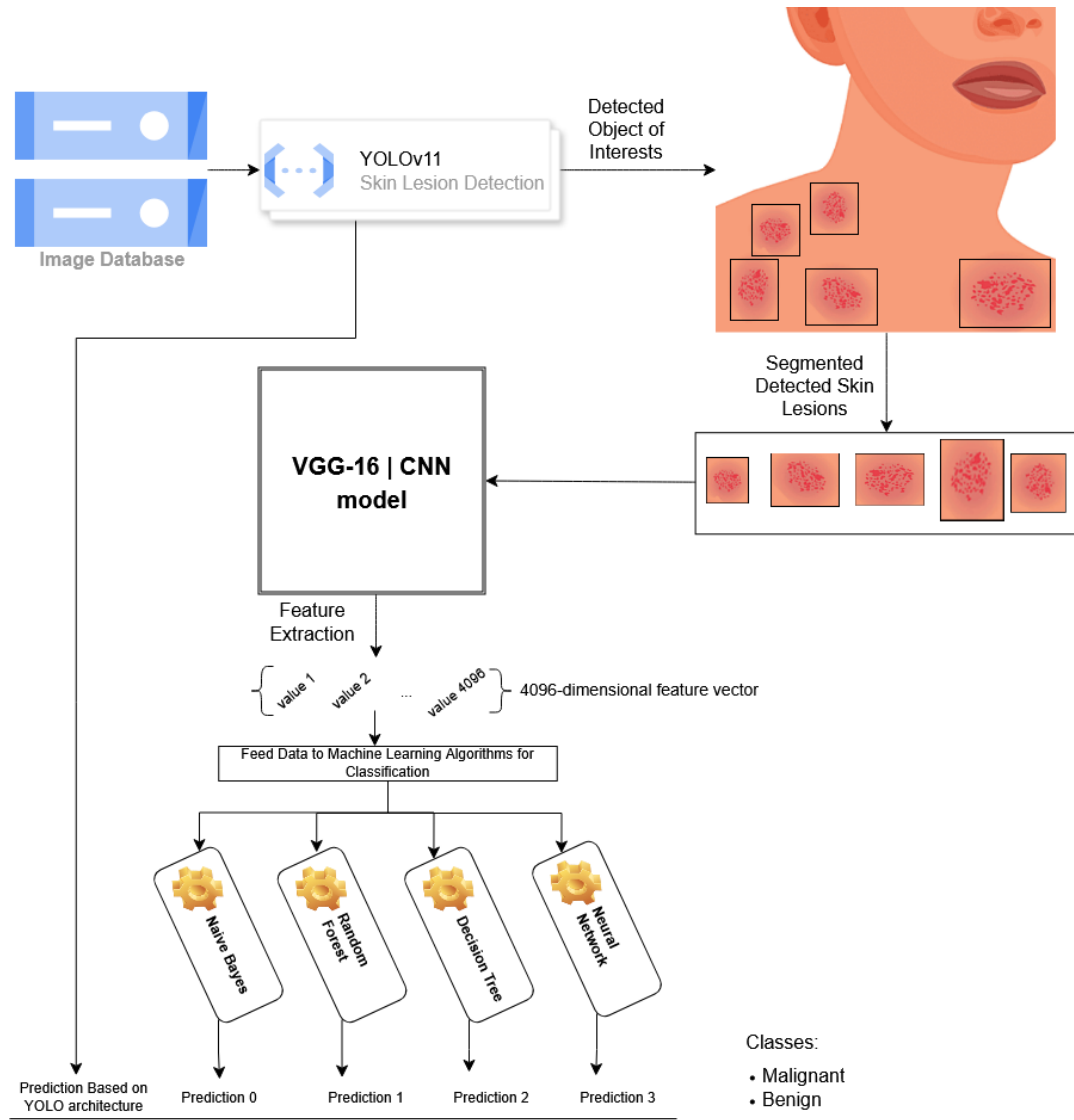
Иницијално искорисена е YOLO архитектурата која се заснова на длабоки наворонски мрежи, која прави селекција на области на самата слика, при што се обидува да издвојува објекти од интерес каде се среќаваат идентични карактеристики како оние врз кој е трениран моделот и притоа прави класификација на истите согласно сличностите и одликите на соодветните класи од тестирачкото множество слики. Моделот користи алгоритам за детекција на потенцијални области на загриженост каде може да постои опасност од болест на самата кожата, меѓутоа поради тоа што различни болести често изгледаат многу слично, имаат слична боја, облик, изразитост или распространетост, самата детекција не е доволна за сигурно класифицирање на состојбата. При тестирање со YOLO архитектурата увидено е дека, иако моделот доста добро знае да ја воочи областа на загриженост, често знае да погреша при самата класификација, поради горенаведените причини.

Поради тоа, за поконкретна и точна класификација имплементирани се дополнителни алгоритми од машинско учење, класификатори, со чија помош се зголемува точноста при идентификација кон која од класите (бенигни или малигни заболувања) припаѓаат детектираните форми од сликата, односно категоризација. Станува збор за алгоритмите: Naive Bayes, Random Forest, Decision Tree, Neural Network класификатори од библиотеката sklearn.

Извлекување на карактеристики/обележја со кои се тренираат горенаведените модели, се изведува со помош на VGG16 модел базиран на CNN (convolutional neural network) кој екстрахира, т.е. извлекува карактеристики кои ги опфаќаат значителните визуелни шаблони и структури, што е од клучно значење за разликување помеѓу бенигни и малигни заболувања. Некои од спецификациите кои моделот ги согледува при извлекување обележја се: Color Gradients, Corners, Shapes Patterns, Texture Patterns, Edges, Lines, Smoothness, Structure.

2.1. Илустрација на архитектура

Во продолжение е претставен дијаграм кој сликовито ја опишува гореспоменатата идејна архитектура која е обработена во склоп на овој проект.



Дијаграм: Дизајн на Архитектура

3. Валидација на Алгоритмите

За да согледаме точноста и исправноста на наведените алгоритми со кои се прави детекција и класификација, се користат неколку метрики од библиотеката `sklearn`, и тоа: `accuracy_score`, `average_precision_score`, `classification_report`. Овие метрики овозможуваат анализа на перформансите и ефикасноста на искористените модели при самиот проект.

Precision

The proportion of true positives out of all positive predictions: $\text{Precision} = \text{True Positives} / (\text{True Positives} + \text{False Positives})$

Recall (Sensitivity)

The proportion of actual positives correctly identified: $\text{Recall} = \text{True Positives} / (\text{True Positives} + \text{False Negatives})$

F1-Score

The harmonic mean of precision and recall: $\text{F1-Score} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$

Accuracy

The proportion of correctly classified samples: $\text{Accuracy} = (\text{True Positives} + \text{True Negatives}) / (\text{Total Samples})$

Average Precision

The average precision is the weighted mean of precision across all recall levels: $\text{AP} = \sum (\text{Recall Change} * \text{Precision at that Recall})$

Naive Bayes Classifier

Class	Precision	Recall	F1-Score	Support
Benign	0.79	0.85	0.82	100
Malignant	0.84	0.78	0.81	103
Accuracy			0.81	203
Macro avg	0.81	0.81	0.81	203
Weighted avg	0.81	0.81	0.81	203

Accuracy:0.8128

Average Precision: 0.77

Decision Tree Learning

Class	Precision	Recall	F1-Score	Support
Benign	0.88	0.65	0.75	100
Malignant	0.73	0.91	0.81	103
Accuracy			0.78	203
Macro avg	0.8	0.78	0.78	203
Weighted avg	0.8	0.78	0.78	203

Accuracy:0.78

Average Precision: 0.71

Random Forest Classifier

Class	Precision	Recall	F1-Score	Support
Benign	0.88	0.85	0.86	100
Malignant	0.86	0.88	0.87	103
Accuracy			0.87	203
Macro avg	0.87	0.87	0.87	203
Weighted avg	0.87	0.87	0.87	203

Accuracy:0.87

Average Precision: 0.82

Neural Network For Classification

Class	Precision	Recall	F1-Score	Support
Benign	0.94	0.88	0.91	50
Malignant	0.89	0.94	0.92	52
Accuracy			0.91	102
Macro avg	0.91	0.91	0.91	102
Weighted avg	0.91	0.91	0.91	102

Accuracy:0.91

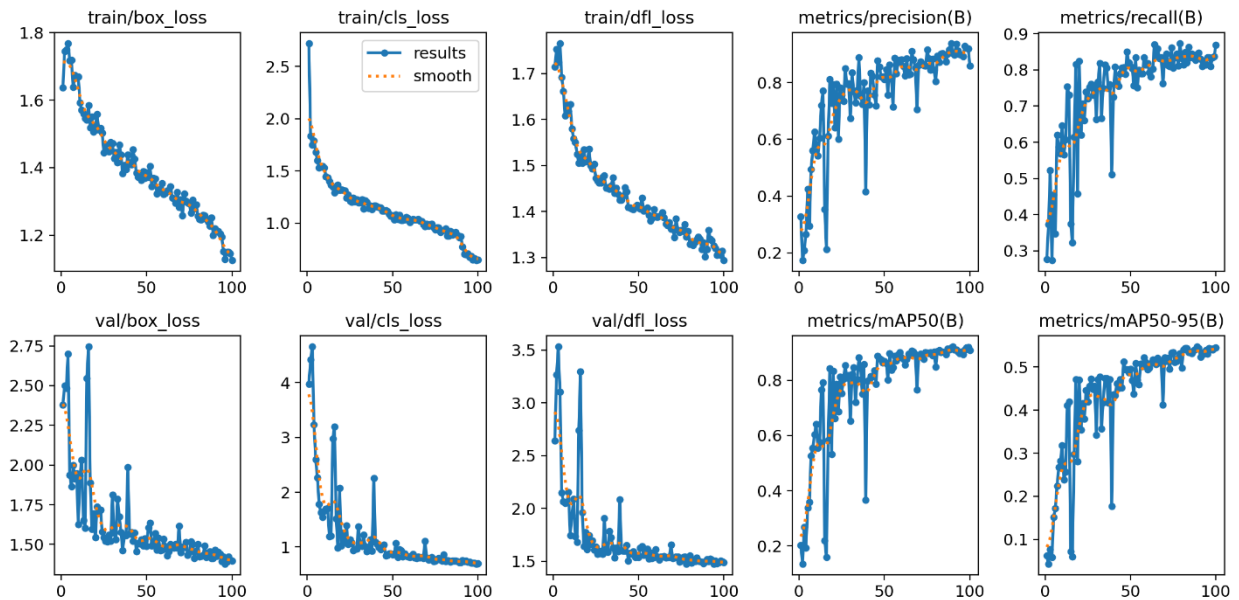
Average Precision: 0.87

3.1. Параметри на YOLO модел

Следната табела ја претставува зависноста при зголемување на бројот на епохи при тренирање на YOLO моделот и како неговите параметри се подобруваат:

Epoch	mAP50 (All)	mAP50-95 (All)	mAP50 (Benign)	mAP50 (Malignant)	Precision (All)	Recall (All)
5	0.623	0.342	0.744	0.501	0.595	0.567
10	0.81	0.438	0.911	0.708	0.783	0.712
25	0.895	0.521	0.953	0.837	0.865	0.823
50	0.896	0.53	0.955	0.836	0.883	0.83
100	0.918	0.547	0.966	0.869	0.939	0.843

Графички приказ на излезните метрики за најдобриот, според табелата, модел трениран на 100 епохи:



3.1.1. Тестирање со различни вредности за рата на учење (Learning Rate) како хиперпараметар кај YOLO моделот

При тестирање со различни вредности за learning rate (0.001, 0.0001, 0.005 и 0.01) се покажаа дека нема значителен/впечатлив ефект врз перформансите на YOLOv11 моделот за детекција на кожни заболувања. Независно од вредноста на Learning Rate (lr0), моделот конзистентно постигнува mAP50 од 0.896, Precision од 0.883 и Recall од 0.83 за сите класи, со слични резултати за категориите "benign" и "malignant".


4. Евалуација на моделите

Во прилог дадено се податоци кои се произлезени при тестирање на крајниот дел од проектот, каде се бара евалуација на точноста која произлегува од моделите користени при класификација на кожните заболувања.

Во наредната табела претставени се податоци за тоа кој модел, колку точни предвидувања има доколку се земат 10, 50, 100, 250 и 500 примероци за испитување.

Model Predicted Sample Size	YOLOv11	Naive-Bayes	Decision Tree	Random Forest	Neural Network
10	10	10	10	10	10
50	48	44	35	43	46
100	96	90	72	90	95
250	239	230	171	231	243
500	483	435	369	470	486

Исто така, следниот график ја дава прецизноста во проценти на секој од моделите во зависност од големината на податочното множество, т.е. процент на точност при класификација на кожните заболувања при дадени примероци со големина 10, 50, 100, 250 и 500.



5. Резултати

Како илустрација, во продолжение наведени се неколку слики и како со споменатите алгоритми се прави детекција и класификација на истите.

Пример 1




Со останатите алгоритми за класификација се добиваат следните предвидувања:

YOLOv11 Model Prediction Results: malignant. Confidence: 0.724592
Bayes Classifier Prediction: malignant
Decision Tree Classifier Prediction: malignant
Random Forest Classifier Prediction: malignant
Neural Network Classifier Prediction: malignant

Предвидувањето и класификацијата на сите модели се совпаѓа со реалната класа на која припаѓа кожното заболување.

Пример 2



Со останатите алгоритми за класификација се добиваат следните предвидувања:

YOLOv11 Model Prediction Results: benign. Confidence: 0.803509
Bayes Classifier Prediction: benign
Decision Tree Classifier Prediction: benign
Random Forest Classifier Prediction: benign
Neural Network Classifier Prediction: benign

Предвидувањето и класификацијата на сите модели се совпаѓа со реалната класа на која припаѓа кожното заболување.

Податочно множество

This project utilizes the "Skin Cancer Dataset" (Arshad, 2022), available on Roboflow Universe. The dataset consists of 1000 images of various skin conditions, categorized into two groups for training machine learning and computer vision models:

Benign
Malignant

[Link to Dataset](#)

Референци

- [1] Nersisson, R., Iyer, T.J., Joseph Raj, A.N. et al. A Dermoscopic Skin Lesion Classification Technique Using YOLO-CNN and Traditional Feature Model. *Arab J Sci Eng* **46**, 9797–9808 (2021). <https://doi.org/10.1007/s13369-021-05571-1>
- [2] AlSadhan, N.A.; Alamri, S.A.; Ben Ismail, M.M.; Bchir, O. Skin Cancer Recognition Using Unified Deep Convolutional Neural Networks. *Cancers* **2024**, *16*, 1246. <https://doi.org/10.3390/cancers16071246>
- [3] V. Pugazhenth, Sagar K. Naik, Amruta D. Joshi, Shreya S. Manerkar, Vinita U. Nagvekar, et al.. Skin Disease Detection And Classification. *International Journal of Advanced Engineering Research and Science (IJAERS)*, 2019, 6 (5), pp.396-400. 10.22161/ijaers.6.5.53 . hal-02141241